



INTRODUCTION TO DATA ANALYTICS

Data Manipulation

Using Python

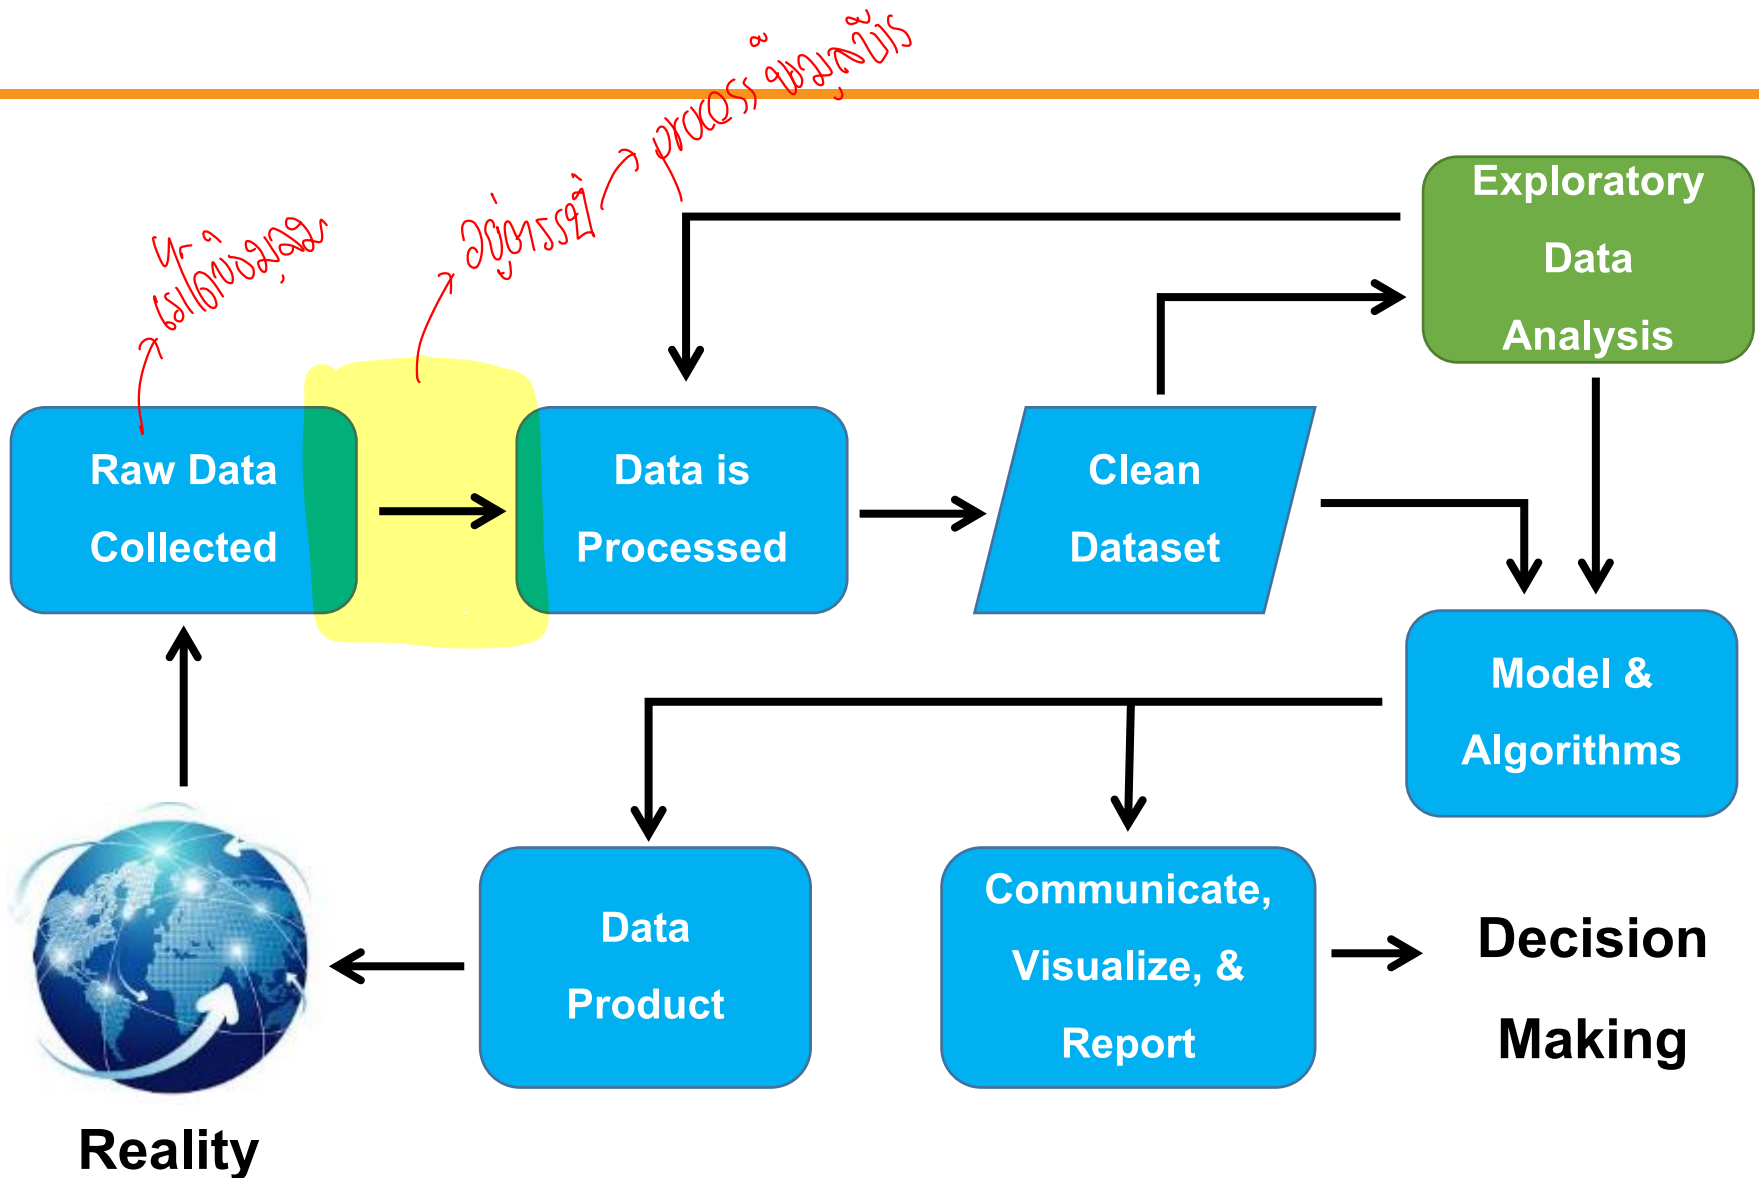
Dr. Rathachai Chawuthai

Department of Computer Engineering

Faculty of Engineering

King Mongkut's Institute of Technology Ladkrabang

Data Science Process



Python

python basic

- List

- [1, 2, "a"]
- [1, 2, 3] + [10, 10, 10] = ? = msconcat
- [1, 2, 3] * 10 = ? ms dup con

- Dictionary

- { "a":1, "b":2 }

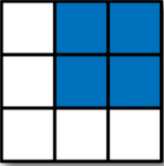
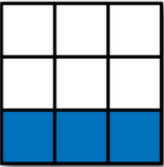
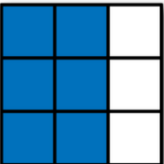
- Tuples

- (1, 2, "a") immutable

Numpy

NumPy (or Numpy) is a Linear Algebra Library for Python, the reason it is so important for Data Science with Python is that almost all of the libraries in the PyData Ecosystem rely on NumPy as one of their main building blocks.

- Array
- Matrix
- Index
- Selection
- Operation

	Expression	Shape
	<code>arr[:2, 1:]</code>	<code>(2, 2)</code>
	<code>arr[2]</code>	<code>(3,)</code>
	<code>arr[2, :]</code>	<code>(3,)</code>
	<code>arr[2:, :]</code>	<code>(1, 3)</code>
	<code>arr[:, :2]</code>	<code>(3, 2)</code>

Pandas

- pandas is an open source, BSD-licensed library providing high-performance, easy-to-use data structures and data analysis tools for the Python programming language.

- Series
- DataFrame
- Operation
- Join DataFrames
- Input and Output
- GroupBy

```
In [2]: 1 iris = sns.load_dataset('iris')
```

```
In [3]: 1 #np.r_ is useful when trying to construct arrays
        2 np.r_[0:5, -5:0]
```

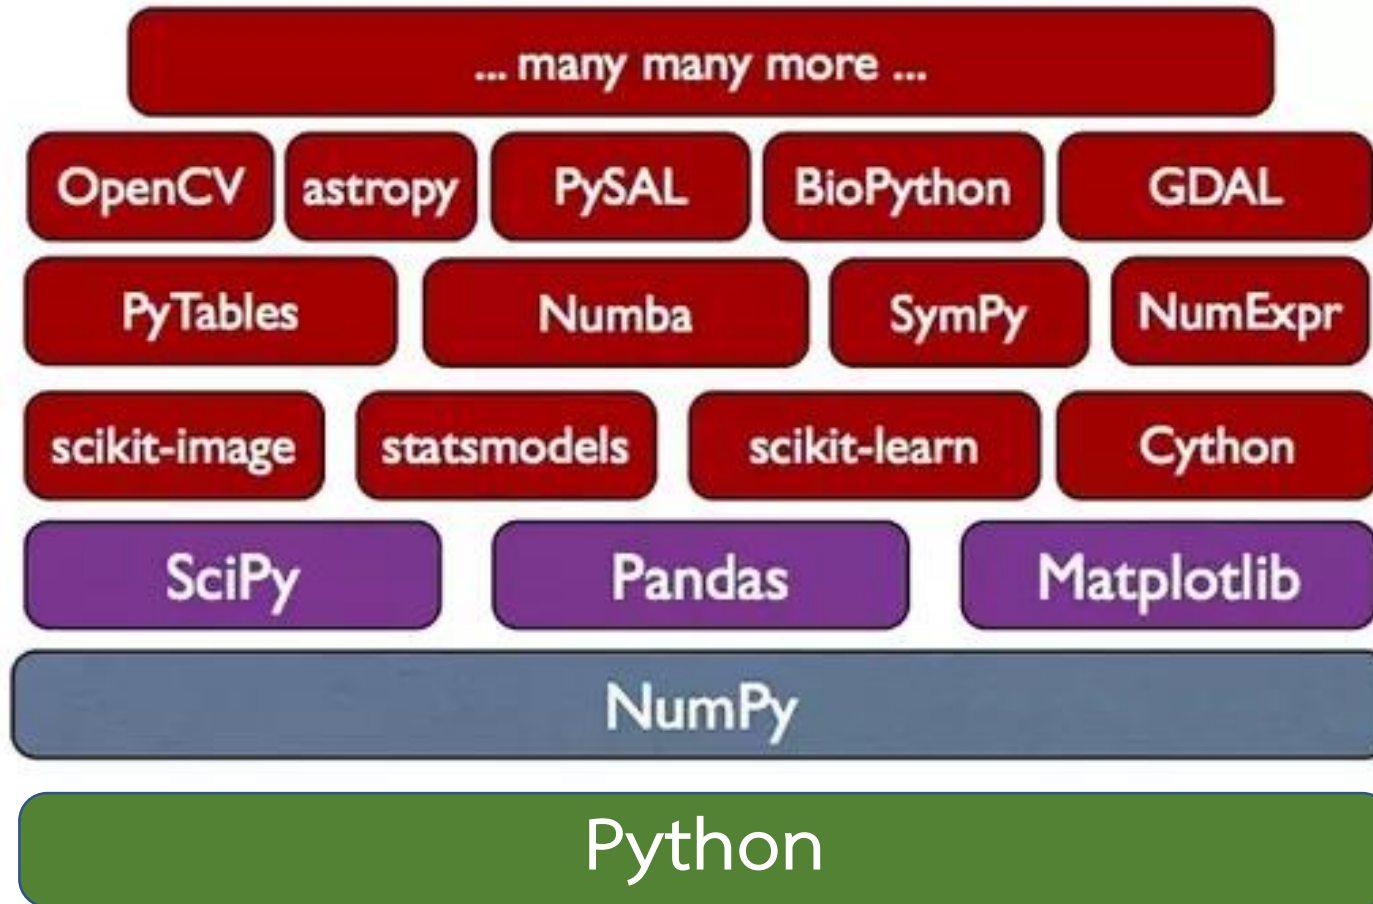
```
Out[3]: array([ 0,  1,  2,  3,  4, -5, -4, -3, -2, -1])
```

```
In [4]: 1 iris.iloc[np.r_[0:5, -5:0]]
```

```
Out[4]:
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa
145	6.7	3.0	5.2	2.3	virginica
146	6.3	2.5	5.0	1.9	virginica

Data Analytics Ecosystem



Next

สัปดาห์หน้าจะเรียน jupyter notebook
และ pandas

↓ เพื่อความสะดวก
จะสอน function ที่รองรับ pandas



INTRODUCTION TO DATA ANALYTICS

Data Manipulation using Python

Dr. Rathachai Chawuthai

Department of Computer Engineering
Faculty of Engineering
King Mongkut's Institute of Technology Ladkrabang

Demonstration

“

Data is the sword of the 21st century,
those who wield it the samurai.

”

Jonathan Rosenberg

การเลือก column อย่าง `df['column']` #series

`df[['column', ...]]` # dataframe

การเลือก row อย่าง

`df.loc[เลขแถว]` #series ^{ถ้า string if type(index) == 'string' ให้}

`df.loc[เลขแถว, ...]` # dataframe

`df.loc[start:stop]` # dataframe

↓
วิธีเลือก
↓
เลขแถว iloc → iloc → เลขแถว array slicing

ให้ add เลขเริ่มต้นให้

↓
ให้ add เลข
ให้ add

combination

↳ ใช้ edit

`df.loc[เลขแถว, ...], ['column', ...]` # dataframe

↳ `df[['column', ...]].loc[เลขแถว, ...]`

↪ เลขแถว df ให้เลือก index

การเลือกด้วย iloc → `df.iloc[index, ...]` #df index location หรือ integer location

↳ เช่น `df.iloc[0,1]['column', ...]` #df

`df[df['column'] operator value]` → ให้เลือกที่เป็น true อย่าง

↓
 $\begin{bmatrix} + \\ + \\ - \\ \vdots \end{bmatrix}$

`gb_obj = df.groupby(['column', ...])`

`gb_obj.mean(), min(), max(), ...`

ถ้าต้องการให้รวมค่า `gb_obj.agg({"mean", "count"})`

↪ ให้กับ column A mean
sum

ถ้าเราเลือก column เดียว

```
gb_obj['age'].agg({...})
```

ถ้าเราเลือก column

```
gb_obj.agg({'column': 'function', ...})
```

```
gb_obj.agg({'column': ['function', ...], ...})
```

↳ กรณีนี้ → select หลาย column → multi index

```
cols = ['_'.join(index) for index in gb_obj.columns.ravel]
```

```
gb_obj.columns = cols
```